

# Pràctica 9: Expressions Regulars (REGEX)

## Lliuraments

Els resultats d'aquesta part de la pràctica s'hauran d'entregar en format PDF i l'entrega pot ser a través de GIT\* o el moodle.

\* S'ha d'entregar l'enllaç del GIT al moodle.

## Exercici 1: Analitza documents XML

Clona el repositori <https://github.com/pauitic/practica9>

Escriu les expressions regulars que seleccionin els continguts que s'indiquen del fitxer **xml\_for\_regex.xml**. Per cada exercici, trobaràs una captura de pantalla que especifica la manera que s'ha de fer la captura de caràcters.

1. Selecciona les etiquetes **<price>** i el seu contingut.  
**<price.\***

```
<name>Belgian Waffles</name>  
<price>$5.95</price>  
<description>  
Two of our famous Belgian Waffl  
</description>
```

2. Selecciona els preus sense l'etiqueta **<price>**

`[\$][0-9].\d{2}`

```

<food>
  <name>Berry-Berry Belgian Waffles</name>
  <price>$8.95</price>
  <description>
    Belgian waffles covered with assorted fresh
  </description>
  <calories>900</calories>

```

3. Selecciona les etiquetes **<description>** i el seu contingut. Compte que ara poden haver-hi salts de línia!

```

<food>
  <name>Belgian Waffles</name>
  <price>$5.95</price>
  <description>
    Two of our famous Belgian Waffles with plenty of real maple syrup
  </description>
  <calories>650</calories>
</food>

```

4. Selecciona totes (i només) les **etiquetes de tancament**.

**</.\*>**

```

<food>
  <name>Belgian Waffles</name>
  <price>$5.95</price>
  <description>
    Two of our famous Belgian Waffles with
  </description>
  <calories>650</calories>
</food>

```

5. Selecciona totes (i només) les **etiquetes d'obertura**.

**<\b[^>]\*>**

```

<food>
  <name>Strawberry Belgian Waffles</name>
  <price>$7.95</price>
  <description>
    Light Belgian waffles covered with strawberries and whipped cream
  </description>
  <calories>900</calories>
</food>

```

## Exercici 2: Analitza documents JSON

Desenvolupa una expressió regular específica per capturar les cadenes de caràcters indicades en el fitxer `json_for_regex.json`. L'expressió regular que utilitzis ha de servir per capturar els *strings* d'aquest document, i no ha de ser genèrica en cap cas.

6. Selecciona totes les **keys** del document JSON juntament amb els dos puntets.

`"(.*)[:]"`

```
"nombre" : "Draculina",
"especie" : "Vampiro",
"habilidades" : ["Transformacion en murcielago", "Control mental"],
"nivel_peligrosidad" : 8,
"region" : "Transilvania",
"es_volador" : true
```

7. Selecciona tots<sup>1</sup> els **valors** (*values*) JSON. Pots utilitzar com a referència els dos punts anteriors i la coma, com es mostra a la imatge.

`[:](.*)"`

`[:]\s(\w*).*`

```
"nombre" : "Draculina",
"especie" : "Vampiro",
"habilidades" : ["Transformacion en murcielago", "Control mental"],
"nivel_peligrosidad" : 8,
"region" : "Transilvania",
"es_volador" : true
},
```

8. Selecciona les **llistes** de *strings* del document.

`\[(.*)\]"`

```
"habilidades" : ["Ilusiones enganosas", "Manipulacion de luz", "Confusion de \"regex\""],
```

9. Selecciona els **booleans**. Compte no seleccionar els strings "true" i "false" dins de *strings*.

`(true|false)$`

---

<sup>1</sup> Excepte el de la clau "monstruos"

```
"nombre": "Fuego Fatuo",
"especie": "Espiritu",
"habilidades": ["Ilusiones enganosas", "Manipulacion de luz y booleanos false", "Confusion de \"regex\""],
"nivel_peligrosidad": 5,
"region": "Pantano Encantado",
"es_volador": false
```

10. Selecciona els **strings**, però no les **keys** (si t'ajuda, pots seleccionar les comes i els ] tal com es mostra a la imatge)  
:(.\*)).

```
{
  "nombre": "Fuego Fatuo",
  "especie": "Espiritu",
  "habilidades": ["Ilusiones enganosas", "Manipulacion de luz y booleanos false", "Confusion de \"regex\""],
  "nivel_peligrosidad": 5,
  "region": "Pantano Encantado",
  "es_volador": false
},
```

## Exercici 3: Troba les paraules

A partir de les següents expressions regulars, identifica **tres paraules** que puguin ser capturades per a cada una d'elles. A més, especifica el **tipus de dades** conegudes a les quals podrien referir-se les diferents expressions:

a.

```
[A-Z][A-Z]\d\d(\d{4}){5}
```

```
AB67 8987 7897 9879 7897 6789
```

contains 2 letters from a-z, 2 digits, a space and 5, 4  
digits number  
car matriculation

b.

```
[1-2]? \d\d (\.[1-2]? \d? \d) {3}
```

```
192.158.1.38
```

ip address

c.

```
\d\d[-/]( [012]\d) [-/]\d\d\d\d
```

date

```
12- 12- 2002
```

d.

```
[0123]\d[-/]( ([012]\d) | [a-z]{3}) [-/]\d\d\d\d
```

```
09-mar-2007
```

date

e.

```
\w*\. (jpg|png|pdf)
```

document.jpg  
file names

## Telèfons

Escriu una expressió regex que validi els telèfons espanyols. Tingues en compte que:

- Pot o no començar amb +34
- El número està format per 9 dígit
- El número comença per 6 o 7 si és mòbil i 8 o 9 si és fix
- Els dígit poden estar seguits o separats per un guionet o espai

`((\+34) )?[6-9]\d ?[-]? \d{3}[-| ]?\d{2}[-| ]?\d{2}`

Casos vàlids	Casos invàlids
645540844 64 554 08 44 74-554-08-44 +34 645540844 +34945540844	+34445540844 64554084 +346+45540844 +34-6455--40844 +34 6455 40844

## DNI / NIE

Escriu una expressió *regex* pels DNIs i NIE

- Els DNI tenen **8 números** i un **dígit de control** alfabètic
- Els NIE comencen per **X, Y o Z**, tenen **7 nombres** i un dígit de **control** alfabètic

`\d{8}[A-Z][XYZ]\d{7}[A-Z]`

Casos vàlids	Casos invàlids
77958643G 00000000X X7958643A Y9999999E	77958643 C7958643Q X7958643 XX958643F Z77958643D

## Correus electrònics

Escriu una expressió regex que validi els emails seguint les següents condicions:

- La paraula que precedeix l'arrova "@" pot tenir lletres no accentuades, números, guions, punts i barra baixes
- El domini de la direcció pot tenir lletres, punts i guions

`[a-zA-Z0-9_.-]+[@]\w.*`

Casos vàlids	Casos invàlids
user2@iticbcn.cat name.surname@iticbcn.cat name_underscore@iticbcn.cat NAME-surname@it-ic.bcn.cat	name.surname@ @iticbcn.cat çç@iticbcn.cat name surname@iticbcn.cat

## Dominiis d'URLs

Escriu una expressió regex que validi els dominis dels URL tenint en compte les següents condicions

- L'URL comença per "http://" o "https://"
- El domini pot tenir lletres, guions, punts
- Pot acabar amb barra

`(https|http):\\V[a-zA-Z.-]+V?`

Casos vàlids	Casos invàlids
https://www.educaciodigital.cat/ https://educacio-digital.fr https://www.educacio	educacio-digital.es http://educacio-digital.cat/hoola/404 http://educacio.digital.cat/nomesDomini

## URLs completes

Escriu una expressió regex que validi els URL tenint en compte les següents condicions

- L'URL comença per "http://" o "https://"
- El domini pot tenir lletres, guions, punts
  - El domini no pot tenir subdomini
  - El domini ha de pertànyer a .es, .cat, .org o .edu
- La ruta pot tenir lletres i números, guions i barra baixes
  - A més, es poden incloure paràmetres, i per això s'han de permetre els símbols ? % & i =
- Pot acabar amb barra

`https?:\V(?:[a-zA-Z.-]+\.)(?:es|cat|org|edu)(?:\V[a-zA-Z0-9_-]*)*(?:\V[a-zA-Z0-9%&_=-]+)?\V?`

Casos vàlids
<p>https://educaciodigital.cat/  http://educacio-digital.cat/apt1/apt3  http://educacio-digital.cat/sim.bo-l_s/me?s?param=1&amp;param2=2</p>
Casos invàlids
<p>http://educacio-digital.cat//DOBLE  http://educacio.digital.cat/te_subdomini  http://educacio_digital.cat/te_barrabaixa_al_domini  https://educacio-digital.fr/fr_no_permes  educacio-digital.es  https://www.educacio</p>

## Adreces

Escriu una expressió regex que validi les adreces que segueixin les següents condicions.

- **Comença** per: C/ Av. Pg. Rb
- Segueix del **nom del carrer** que pot ser una o diverses paraules amb lletres majúscules i minúscules accentuades
- Continua amb el **número de porta** que pot tenir diversos dígit

- Pot tenir **número de pis** i **número de porta**
- Continua amb el **nom de la ciutat**, que pot estar formada per diferents paraules
- Acaba amb la **província** entre parèntesis. Només pot ser Barcelona, Girona, Tarragona o Lleida.

(CV|Av\.|Pg\.|Rb) \p{L}+(?: \d+)?(?: [1-9]\d\*)?, \p{L}+(?: \p{L}+)\*(?: [1-9]\d\*)?, \p{L}+(?: \p{L}+)\* (Barcelona|Girona|Tarragona|Lleida) \((?:Barcelona|Girona|Tarragona|Lleida)\)\$

Casos vàlids
C/ Diputació 31 1 2 Badalona (Barcelona) Av. Girona 42 1 2 Badalona (Barcelona) Av. Rossello 35 Arbucies (Girona) Rb. Les Rambles 4432 Lleida (Lleida) Av. Gran via de les corts catalanes 32 Santa Coloma de Gramanet (Barcelona) Av. Rosselló 32 1 2 Reus (Tarragona)
Casos invàlids
Av. Gran via de les corts catalanes 32 (Barcelona) Gran via de les corts catalanes 32 Badalona (Barcelona) C/ 32 1 2 Badalona (Barcelona) Av. Rosselló 32 1 2 4 Salt (Girona)

## Contrasenyes fortes

Dissenya una expressió regex que validi les contrasenyes fortes.

- Com a mínim ha de tenir una lletra **majúscula** i una **minúscula**
- Com a mínim ha de tenir **dos dígit**s
- Com a mínim ha d'incloure un dels següents **símbols**: . \_ ? \ [ ] ( )
- La contrasenya ha de tenir entre **8 i 30 caràcters**

Casos vàlids	Casos invàlids
12345678aA._? aA._?12345678	123456789 aA77._



aA\[]()12345678	77fghgfAAAAA
-----------------	--------------